

Autenticación de obras pictóricas mediante Inteligencia Artificial Explicable (XAI): Estudio aplicado a obras de Goya y Velázquez

Sara Avero Méndez¹, Ángel García Pérez¹, Yanira de la Peña Guerra Guerra¹
Arturo Martínez Martínez¹, Laura Rodríguez Ropero¹, Luis Sandoval Díaz¹

¹ *Máster Big Data, Data Science e IA, Universidad Complutense de Madrid*

Resumen

Este trabajo aborda la atribución de autoría pictórica mediante un sistema compuesto por varios modelos y capaz de clasificar obras como hechas por Goya o por Velázquez. El dataset usado para el proyecto es de elaboración propia, utilizando imágenes de Wikimedia y validándolas con bibliografía.

Usando Inteligencia Artificial Explicable (XAI), se intentan obtener evidencias visuales que refuercen el resultado de cada modelo. Los modelos buscan basarse en criterios similares a los que usan los expertos dedicados a la autenticación de arte. Para ello, se utilizan modelos específicos centrados en características estudiadas por expertos, como el color y las caras; además de modelos más generalistas, utilizando las técnicas de XAI para visualizar los trazos más relevantes

Se usa un Random Forest para el color, con una explicación SHAP TreeExplainer. Sobre los cuadros completos se aplican modelos CNN y Swin-Tiny, explicados mediante Grad-CAM e Integrated Gradients. Por último, se analizan las caras pintadas en los cuadros utilizando un modelo ViT y uno de Embeddings, explicándolos mediante SmoothGrad, Attention Rollout, y LIME. Los resultados de estos modelos se ensamblan en una regresión logística, obteniendo un resultado de una Accuracy del 0.98 y un F1-score del 0.99. Finalmente, se entrena un LLM para que explique la clasificación final en base a los modelos.

Por último, se abordan metodologías exploradas y descartadas, se expone una aplicación gráfica que utiliza los modelos y se proponen futuras extensiones de este trabajo que puedan aportar valor.

Palabras Clave: Autenticación de obras, Vision Transformers, CNN, Swin-Tiny, Embeddings, XAI, LLM, SHAP, Grad-CAM, Integrated Gradients, SmoothGrad, Attention Rollout, LIME, Regresión logística.

1. Introducción

1.1. Contexto y motivación

En la historiografía del arte, el análisis sistemático de una obra suele comenzar con la fase pre-iconográfica descrita por Panofsky (1939), centrada en la observación técnica y formal de los elementos visibles: color, composición, formas, texturas sin todavía asignarles un significado simbólico.

Inspirado en este enfoque, este trabajo busca replicar esa primera aproximación utilizando herramientas contemporáneas de inteligencia artificial: modelos de visión artificial para capturar la estructura visual y un modelo cromático que cuantifica las variaciones tonales. Este tipo de análisis es especialmente relevante en la autenticación y atribución de autoría, donde la

objetividad y la trazabilidad de las decisiones resultan esenciales.

Además, la incorporación de técnicas de Inteligencia Artificial Explicable (XAI) permite no solo obtener predicciones, sino también comprender y justificar cada resultado ante expertos humanos.

1.2. Objetivo del trabajo y enfoque

El objetivo de este estudio es diseñar y evaluar un sistema de autenticación pictórica que combine modelos de clasificación visual y cromática con métodos de XAI y generación de explicaciones en lenguaje natural mediante modelos de lenguaje (LLMs). El sistema busca ofrecer una predicción final acompañada de evidencias visuales y textuales que faciliten su validación por especialistas.

1.3. Metodología general

El sistema propuesto integra múltiples clasificadores especializados: una CNN y un Swin-Tiny que procesan la imagen completa, un modelo cromático basado en métricas de color extraídas a formato JSON y, de forma opcional, modelos adicionales entrenados sobre recortes específicos o segmentos de la obra. Cada modelo se explica mediante técnicas XAI adecuadas a su naturaleza. Las predicciones y explicaciones intermedias se combinan en un ensamblado mediante regresión logística, cuya salida final es procesada por un LLM para generar una explicación global coherente y comprensible para expertos.

2. Marco teórico y conceptual

2.1. IA en el dominio artístico

La clasificación de autoría y la autenticación de obras de arte son tareas fundamentales en el ámbito de la historia del arte, la conservación y el mercado artístico. Estas disciplinas buscan determinar si una obra es auténtica o si pertenece al corpus de un autor específico, utilizando para ello criterios estilísticos, materiales y técnicos. En los últimos años, el uso de algoritmos de aprendizaje automático ha permitido automatizar parte de este proceso, analizando patrones visuales y características cuantitativas que pueden pasar desapercibidas al ojo humano.

Investigaciones previas han explorado el uso de redes convolucionales profundas (DCNNs) para la clasificación estilística, la detección de falsificaciones y la atribución de autoría. Por ejemplo, el trabajo de Sabatelli et al. (2019) aplicó aprendizaje por transferencia sobre modelos preentrenados como VGG y ResNet para clasificar obras según su autor y estilo, evaluando el rendimiento en conjuntos de datos artísticos de gran escala y demostrando que la reutilización de características aprendidas en dominios generales puede ser efectiva en el dominio pictórico. Más recientemente, Sano (2024) desarrolló modelos de clasificación de artistas utilizando arquitecturas como ResNet-50, VGG19 y Vision Transformers, incorporando *Gradient-weighted Class Activation Mapping* (Grad-CAM) para visualizar las regiones de la imagen más influyentes en la predicción.

2.2. Modelos de visión artificial

Las redes neuronales convolucionales (CNN) han sido ampliamente utilizadas en visión artificial debido a su capacidad para extraer jerarquías de características visuales a partir de píxeles. Modelos como ResNet o VGG han marcado hitos en la clasificación de imágenes. Más recientemente, los Vision Transformers (ViT) y sus

variantes, como Swin-Tiny, han introducido arquitecturas basadas en mecanismos de atención, capaces de modelar relaciones globales entre regiones de la imagen.

A pesar de los avances en la clasificación automática de obras mediante aprendizaje profundo, la naturaleza opaca de estos modelos plantea un reto importante: comprender y justificar sus decisiones ante expertos humanos. En este contexto, la Inteligencia Artificial Explicable (XAI) se presenta como la estrategia predilecta para dotar a estos sistemas de transparencia, ofreciendo herramientas que permiten visualizar, interpretar y validar los factores que influyen en cada predicción. De este modo, la XAI no solo contribuye a aumentar la confianza en el resultado del modelo, sino que también facilita su integración en procesos críticos como la autenticación de autoría, el análisis estilístico o la conservación de patrimonio artístico.

2.3. XAI

La **Inteligencia Artificial Explicable** (XAI, por sus siglas en inglés) es un campo de investigación que tiene como objetivo hacer que los resultados de los sistemas de IA sean más comprensibles para los humanos Adadi and Berrada (2018).

En este trabajo se adopta una clasificación de técnicas de XAI que combina elementos de la propuesta de Arrieta et al. (2019) y la de Molnar (2025), adaptada a las necesidades del sistema desarrollado.

Se distinguen dos grandes categorías iniciales:

1. **Modelos intrínsecamente interpretables** (transparentes), cuyo funcionamiento es comprensible por diseño (ej. árboles de decisión, regresiones lineales y logísticas, GAMs, ...).
2. **Modelos de caja negra** (black box), que requieren la aplicación de técnicas post-hoc para generar explicaciones una vez entrenados (ej. SVMs, CNNs, RNNs, ...).

Las técnicas post-hoc pueden clasificarse según su grado de dependencia del modelo en el que se aplican, distinguiendo entre:

- Model-agnostic: independientes del tipo de modelo, aplicables a cualquier arquitectura.
- Model-specific: diseñadas para un tipo concreto de modelo o arquitectura, aprovechando su estructura interna.

Y a su vez por su tipología, contemplando:

- **Explicaciones textuales:** generan descripciones en lenguaje natural o mediante símbolos que representen el razonamiento interno del modelo, mapeando su funcionamiento a un formato comprensible (ej. *caption generation*).
- **Explicaciones visuales:** representan gráficamente el comportamiento del modelo, a menudo combinadas con técnicas de reducción de dimensionalidad, y resultan especialmente útiles para usuarios no especializados (ej. Grad-CAM, SmoothGrad).
- **Explicaciones locales:** explican únicamente una parte del funcionamiento del modelo, normalmente asociada a una predicción específica, mediante el análisis de un subconjunto de características relevantes (ej. LIME, Shapley values/SHAP, Anchors).
- **Explicaciones por ejemplo:** ilustran el comportamiento del modelo mediante instancias concretas de los datos que son representativas de un patrón de decisión (ej. *activation clusters*).
- **Explicaciones por simplificación:** generan un modelo sustitutivo más simple que imita el comportamiento del original, reduciendo su complejidad y facilitando su comprensión (ej. *rule-based learners*, árboles de decisión).
- **Relevancia de características:** cuantifican la influencia de cada variable sobre la salida del modelo, evaluando su importancia o sensibilidad en la predicción (ej. Integrated Gradients, SHAP, Permutation Importance, *Ceteris Paribus* profiles, ICE).

Como se muestra en el Cuadro 1, en este trabajo se priorizan métodos que ofrezcan salidas visuales interpretables y fácilmente exportables para su análisis interactivo. En los modelos visuales de imagen completa (ConvNeXt-Tiny y Swin-Tiny), así como en el ViT aplicado a rostros, se emplean principalmente Grad-CAM Selvaraju et al. (2019) e Integrated Gradients Sundararajan et al. (2017), complementados en los transformadores con técnicas como Attention Rollout o Transformer-CAM, por su capacidad de resaltar las regiones de la imagen que más contribuyen a la predicción. En el caso del modelo de embeddings faciales, se utilizan aproximaciones model-agnostic como LIME Ribeiro et al. (2016) y SHAP aplicados a las distancias de embedding, además de ejemplos prototípicos que permiten interpretar la similitud entre rostros. Para el modelo cromático basado en Random Forest, se aplican SHAP TreeExplainer, LIME y Partial Dependence Plots (PDPs), que permiten estimar y visualizar la relevancia e influencia de cada variable cromática tanto a nivel global como local.

Finalmente, en la regresión logística que integra todas las predicciones individuales, se emplean coeficientes normalizados, y SHAPs, lo que permite cuantificar el peso relativo de cada modelo en la decisión final.

Modelo clasificador	Métodos XAI aplicados
Modelo cromático (RF)	SHAP TreeExplainer
ConvNeXt-Tiny (CNN)	Grad-CAM, Integrated Gradients
Swin-Tiny (ViT)	Integrated Gradients
ViT sobre caras	SmoothGrad, Attention Rollout
Modelo de embeddings faciales	LIME

Cuadro 1: Asignación de métodos XAI.

En el ámbito de la autenticación pictórica, la XAI aporta un valor añadido al permitir contrastar las predicciones automáticas con criterios comprensibles para expertos en arte. En los modelos visuales, las representaciones gráficas obtenidas permiten localizar en la obra elementos clave para la decisión del modelo, mientras que en el modelo cromático las métricas de importancia y dependencia ayudan a identificar patrones de color característicos del autor o del periodo. Esta información complementa las métricas de rendimiento y contribuye a fundamentar las conclusiones en evidencias visuales y cuantitativas.

2.4. Modelos de lenguaje (LLMs) como capa explicativa

Los Modelos de Lenguaje de Gran Escala (LLMs) se utilizan en este trabajo como una capa adicional de explicabilidad. Cada clasificador genera una predicción y su correspondiente explicación mediante técnicas XAI, que se suministran como entrada a un LLM para producir un texto explicativo comprensible para un humano. Además, se agregan las salidas de todos los modelos para generar una predicción final, que junto con las explicaciones intermedias se utiliza como entrada a un LLM final encargado de elaborar una explicación global. Este flujo tiene como objetivo facilitar la validación por parte de expertos y minimizar la posibilidad de errores o alucinaciones por parte del sistema.

3. Arquitectura del sistema propuesto

3.1. Descripción general del flujo




Figura 1: Flujo del modelo.

3.2. Métodos XAI

Debido al valor que aporta, no solo la predicción final de modelo, sino el propio análisis y exploración subjetiva e intuitiva de los resultados obtenidos, salta a la vista la importancia de tratar la explicabilidad de los modelos usados para llegar a la conclusión final sobre la autoría de los cuadros.

Esto puede ser un reto cuando se trata de modelos calificados a menudo como “cajas negras”, como son las redes neuronales utilizadas. Frente a este desafío se recurre a diversas y contrastadas técnicas de XAI para poder entender de forma intuitiva, no solo los resultados, sino cómo han llegado a ellos los modelos utilizados.

Grad-CAM

En el caso del modelo basado exclusivamente en redes convolucionales, el problema de la explicabilidad se afronta mediante el uso del método Grad-CAM, usado a menudo para este tipo de modelos Selvaraju et al. (2019) por su explicabilidad intuitiva mediante un mapa de calor, que permite observar las regiones de la imagen más relevantes para que el modelo atribuya a uno u otro autor el cuadro gracias a la representación gráfica de los gradientes obtenidos en la última capa convolucional del modelo.

Es mediante la implementación de este método que se observa, a grandes rasgos, en qué posibles características del cuadro se debe centrar la atención para resolver el problema de clasificación que puedan estar escapándose a la heurística del análisis de color, caras, manos y figuras. Esto aporta una nueva visión al análisis del arte que escape de los métodos tradicionales

para evaluar autoría: la visión artificial.



Figura 2: Aplicación de Grad-CAM sobre *General Antonio Ricardos Carrillo de Albornoz* (Goya, 1794).

Integrated Gradients

En el modelo basado en Swin-Tiny, se usa Integrated Gradients (IG) para explicar de forma fiel y a nivel de píxel qué regiones de cada parche 224×224 px empujan la predicción hacia Goya o Velázquez. IG es un método de atribución ampliamente utilizado porque produce un mapa de calor interpretable que indica dónde es más sensible el modelo al calcular el score de una clase.

En este caso, la predicción del cuadro completo se obtiene promediando los logits de todos los parches. Para entender por qué se toma esa decisión, primero se seleccionan los parches más influyentes con una prueba leave-one-out sobre el logit medio (el que más apoya la clase predicha y el que más se opone). Después, aplicando IG por parche se calcula el gradiente del logit objetivo ($\text{logit}(\text{Goya})$) o su negativo para explicar Velázquez) a lo largo de un camino conti-

nuo desde una imagen de referencia hasta la imagen real del parche, y esas sensibilidades son acumuladas. Usando como imagen de referencia un tensor de ceros tras la normalización se tiene una imagen con los valores medios del dataset, y se recorre desde ese punto neutro hasta el parche original. El resultado es un mapa de calor por parche que resalta, con detalle, bordes, pliegues y micro-contrastes que el modelo considera evidencia para la clase explicada; después, es suavizado y normalizado para facilitar la lectura.

Para la visualización a nivel de rejilla del cuadro com-

pleto se mantiene una convención fija y consistente: Rojo = Goya y Azul = Velázquez. La intensidad del color refleja lo seguro que está el modelo en cada celda (proporcional a lo lejos que esté $p(\text{Goya})$ de 0,5) y en el centro de cada parche se muestra la $p(\text{Goya})$ numérica. Finalmente, se destaca con IG los dos parches clave detectados por leave-one-out (el que apoya la predicción y el que se opone) para visualizar de forma clara la evidencia a favor y en contra. Todo se ejecuta con el modelo en modo evaluación y con semillas fijadas para asegurar reproducibilidad.



Figura 3: Aplicación de Integrated Gradients en la obra *La túnica de José* (Velázquez, 1630).

SHAP TreeExplainer

Para los modelos basados en árboles, existen diversos métodos sencillos para obtener las importancias que tienen las variables, de manera que se puede saber, dada una de ellas, si tiene un impacto mayor o menor en la probabilidad final. Sin embargo, estas importancias no te dicen si, en una observación particular, cierta variable aporta más o menos, y en qué dirección.

Una herramienta muy potente de explicabilidad son los SHAP (SHapley Additive exPlanations). Estos métodos aprovechan la estructura de los árboles para obtener el impacto de cada variable en el resultado final, rastreando cada segmentación de cada árbol para obtener la aportación de cada variable al resultado final. La diferencia principal entre las importancias y los valores shap es que estos últimos obtienen la importancia de cada variable en una observación en concreto, en vez de la importancia general que una variable tiene en el modelo. Por ejemplo, una cierta variable puede tener

una gran importancia en un modelo, pero si en una cierta observación, esa variable toma el valor medio, entonces, no te dice realmente nada sobre la salida del modelo; y entonces su valor shap sería cercano a 0.

Este método solo se puede aplicar a modelos basados en árboles, como el modelo de color que se explica más adelante.

LIME

En el caso del modelo basado en embeddings faciales y un clasificador de aprendizaje automático, el problema de la explicabilidad es abordado mediante la técnica LIME (Local Interpretable Model-Agnostic Explanations) Ribeiro et al. (2016). Este método es especialmente adecuado por su carácter agnóstico al modelo, lo que permite explicar cualquier clasificador, incluso aquellos considerados como cajas negras, a partir de un modelo interpretable ajustado de forma local a cada predicción.

La idea central de LIME es generar un conjunto de perturbaciones de la instancia original (en este caso, la imagen facial), observar cómo varía la predicción del clasificador sobre dichas perturbaciones y, finalmente, ajustar un modelo lineal interpretable que aproxime el comportamiento del clasificador en la vecindad de esa predicción. Para imágenes, esta representación interpretable se logra mediante superpíxeles, que son regiones contiguas y visualmente homogéneas. De esta forma, es posible identificar qué zonas concretas de la cara contribuyen de manera más significativa a que el modelo asigne un cuadro a Goya o a Velázquez.

En este trabajo, LIME permite visualizar regiones faciales relevantes que el clasificador utiliza para su decisión, resaltando, por ejemplo, áreas en torno a los ojos, la boca o el cabello como determinantes en la atribución de autoría. Esta técnica brinda una herramienta para contrastar las predicciones del modelo con criterios comprensibles, facilitando así el análisis crítico. Además, siguiendo lo demostrado por Ribeiro et al. (2016), estas explicaciones locales no solo aumentan la confianza en predicciones individuales, sino que también ayudan a detectar posibles sesgos o correlaciones espurias en el modelo.

En la imagen a continuación se muestra un ejemplo de aplicación de LIME sobre una de las obras analizadas, donde se destacan las regiones que más influyen en la clasificación como Velázquez. A diferencia de las visualizaciones basadas en mapas de calor globales, LIME resalta fragmentos discretos de la imagen, lo que proporciona una lectura complementaria y granular de los elementos pictóricos que el modelo considera característicos de cada autor.



Figura 4: Aplicación de LIME en una obra de Velázquez.

Smooth Gradients

En el modelo de clasificación de caras basado en ViT, se emplea Smooth Gradients (SmoothGrad) Smilkov et al. (2017) para obtener mapas de saliencia. La saliencia es una medida de cómo de sensible es la predicción en función de cada variable de la entrada, es decir, cuánto afecta cada píxel al resultado de la predicción.

Esto se realiza introduciendo ruido gaussiano normal a la cara y midiendo cómo afecta la variación de cada píxel a la predicción, es decir, su gradiente. Este proceso se repite varias veces (en este caso $n = 50$), y finalmente se hace la media de estos valores que se obtienen por píxel en cada una de las mediciones de variación de gradiente. El resultado se normaliza y se representa en forma de mapa de saliencia y mapa de calor sobre la imagen original. Además, la normalización de las caras a 224×224 contribuye a que este proceso no lleve un tiempo de computación demasiado rápido.

Para implementar este método, se han construido funciones propias, sin necesidad del uso de librerías. Los resultados se pueden observar en la Figura 5. Como se observa, en este caso, parece que los píxeles que más influyen en la predicción final son los que parecen componer las cejas, los labios y el contorno de la cara, lo cual supone una explicación visual bastante buena.



Figura 5: Aquí se observa un cuadro de Goya, su mapa de saliencia y por último, la saliencia suuerrpuesta en forma de mapa de calor.

Attention Rollout

También para el modelo de clasificación de caras basado en ViT, utilizamos Attention Rollout Abnar and Zuidema (2020) para obtener un "mapa de atención" a partir de los propios pesos de auto-atención de los *transformers*, sin calcular gradientes. El procedimiento extrae, en cada capa, las matrices de atención de todas las cabezas, calculando la media para obtener una matriz por capa, suma la identidad (para reflejar las conexiones residuales) y normaliza por filas. A continuación, compone estas matrices mediante el producto a lo largo de las capas, de forma que la fila correspondiente al token [CLS] (el token de clase, que recibe toda la información de los anteriores) describe cuánta información fluye hacia cada el token de cada recuadro. A este vector se le da la forma de una cuadrícula 14×14 (ya que el ViT-B/16 divide la

imagen en cuadros de 16×16 píxeles) y se reescalan los valores al tamaño de la cara, generando un mapa de calor que podemos superponer con un colormap para visualizar las zonas que contribuyen con más información.

Como limitación, conviene recordar que atención no implica causalidad: un valor alto indica fuerte conectividad/flujo de información, no necesariamente la mayor contribución marginal al logit. Por ello, en el trabajo se utiliza de forma complementaria a los mapas de saliencia. Cuando ambos coinciden, aumentan la confianza en la explicación; cuando difieren, ayudan a matizar la interpretación.

Al igual manera, tampoco se han usado librerías adicionales para este proceso. Como se puede ver en la Figura 6, los resultados son menos claros que en el caso del SmoothGrad, ya que no parecen señalar a ninguna zona en concreto. Sin embargo, esto es normal, ya que se fija en zonas más globales de la cara, y no en los detalles tan finos.




Figura 6: Aquí se observa un cuadro de Goya, el mapa de las zonas que más flujo de información tienen y por último, la superposición en forma de mapa de calor.

Explicabilidad directa de regresiones logísticas

Las regresiones logísticas son, por construcción, muy explicables de por sí. Por ello, no son necesarios complejos modelos de explicabilidad, y se puede obtener de manera precisa cuánto es el impacto de cada variable multiplicándola por su coeficiente asociado y tomando esto como una proporción del total de logodds que dan lugar a la probabilidad dada por el modelo a esa observación.

4. Implementación y experimentación

4.1. Datos utilizados

Para elaborar el conjunto de datos se ha recurrido a diversas fuentes. En primer lugar, se desarrolló un script que realizó *scraping* de los catálogos de ambos pintores disponibles en *Wikipedia*, a partir del cual se obtuvo una primera lista de cuadros que incluía: el título, el año de realización, el enlace a la imagen en mayor resolución disponible en *Wikimedia Commons* y las dimensiones originales de la obra. Las páginas consultadas fueron Wikipedia (2025c) para Velázquez y Wikipedia (2025a), Wikipedia (2025b) para Goya. Posteriormente, se llevó a cabo una limpieza manual de los datos.

Con el fin de verificar la autoría y la exactitud de la información obtenida en dichas páginas web, se consultó la página de la Fundación Goya en Aragón Fundación Goya en Aragón (2025) para los cuadros de Goya, que ofrece datos precisos de cada obra, así como los libros López-Rey (1963) y Brown (1986), que constituyen los principales catálogos de Velázquez. Para garantizar la fiabilidad, únicamente se tuvieron en cuenta aquellas obras en las que ambas fuentes coincidían.

Además, se eliminaron copias, ya que es frecuente que haya bocetos o varias versiones de un mismo cuadro. Por ejemplo, en la Figura 7 se ven las cuatro versiones que existen del retrato de Inocencio X. Se sospecha que las de la primera fila fueron hechas por Velázquez y las de abajo por su taller. Por ello únicamente se toma el que ambos autores López-Rey (1963) y Brown (1986) eligen como el cuadro original pintado únicamente por Velázquez.



Figura 7: Versiones del retrato de Inocencio X.

Tras la limpieza, restan 168 cuadros de Goya y 93 de Velázquez. Se dividió el conjunto de datos en train (70 %), test (20 %), validation (10 %), guardando dos imágenes de cada autor para las comprobaciones finales. El recuento total de los cuadros es así:

	Total	Goya	Velázquez
train	181	117	64
test	51	33	18
validation	25	16	9
check	4	2	2

Cuadro 2: Distribución del conjunto de datos.

La gran mayoría de los cuadros pintados por ambos pintores fueron retratos, así que había caras suficientes en los cuadros. Las caras fueron extraídas con el modelo que se explica en la Sección 3, y se asignaron al conjunto del que provenían. Las caras de la Figura 7 fueron extraídas usando este modelo. De esta manera, el recuento final es:

CARAS	Total	Goya	Velazquez
train	124	79	45
test	38	25	13
validation	17	11	6
check	4	2	2

Cuadro 3: Distribución del conjunto de caras.

4.2. Modelos individuales

4.2.1. Modelo cromático (JSON)

Dado el enfoque de este trabajo, centrado en la explicabilidad de los resultados obtenidos, el primer modelo que se desarrolla es uno que estudia el color, uno de los primeros pasos naturales que estudiaría un experto en la materia.

El color de un cuadro en sí mismo puede dar mucha información sobre el autor, la intención o el tema sin ni siquiera fijarnos en elementos concretos. Además, estudiar el color tiene la ventaja de que no tiene dependencia espacial, ya que se estudia píxel a píxel.

Además, y continuando el afán de una mayor explicabilidad, el modelo que estudie el color será uno muy sencillo basado en métricas sobre la distribución del color que estarán predefinidas, de manera que se pueda observar cómo influye cada una de ellas en el resultado final.

Para ello, se definen los siguientes puntos de los que extraer características:

- **Colores principales de la obra**

Para analizar los colores principales de la obra, se transforma cada píxel en un punto del espacio RGB, y después se normaliza para que cada componente esté entre 0 y 1. A continuación, se le aplica a este conjunto de puntos un algoritmo KMeans con 5 clústeres, de manera que se divida

todos los píxeles en 5 grupos. Una vez agrupados los píxeles, se escoge el centroide de cada clúster como un color principal. De estos colores principales, se añade al modelo las coordenadas RGB de cada uno y la proporción que representa su clúster respecto al total.

- **Estadísticas de los colores en el espacio RGB**

En este punto, se obtienen las características principales de cada uno de los canales del espacio RGB, es decir, que se obtienen la media, desviación típica, simetría y curtosis del canal rojo, verde y azul.

- **Estadísticas de los colores en el espacio HSV**

Similar al punto anterior, pero proyectando los valores de cada píxel sobre el espacio HSV. Es decir, que se obtienen la media, desviación típica, simetría y curtosis del matiz, saturación y brillo.

- **Otras características cromáticas generales**

Se estudian además otras métricas, como la entropía, la dispersión, el rango dinámico, y el porcentaje de tonos claros y oscuros.

Una vez obtenidas todas estas medidas, el modelo que se entrena es un *Random Forest*, un tipo de modelo que combina un adecuado poder predictivo con buena explicabilidad, pudiendo obtener cuáles son las importancias de cada una de las variables. Además, esto se combina con *shap.TreeExplainer* del modelo, de manera que se obtiene exactamente qué parte de la probabilidad final dada por el modelo aporta el valor de cada variable.

Una vez entrenado el modelo, a la hora de evaluar un nuevo cuadro (en el test o en un cuadro al que se le quiera aplicar el modelo), se obtendrán las estadísticas cromáticas de ese cuadro en concreto, y se le aplica el modelo.

A continuación, se guardará en formato JSON la siguiente información:

- Resultado expedido por el modelo.
- Probabilidad asociada
- Valor de cada variable en el cuadro, junto con el valor shap asociado a esa variable por el *shap.TreeExplainer*
- Valor shap total de las variables que se midan por canales (por ejemplo, el impacto total del primer centroide se obtiene como la suma de los impactos de las coordenadas *R*, *G* y *B* de dicho centroide)

Resultados




Figura 8: Matriz de confusión en el conjunto de prueba para el Random Forest de color.

- **Accuracy:** 0,71

- **Recall:** 0,70

- **F1-score:** 0,75

4.2.2. Modelo CNN

En segundo lugar, se exploran características abstractas y patrones ocultos a la heurística humana tradicional en el arte que únicamente fueran observables mediante el uso de visión artificial. De este modo, se aporta una perspectiva única respecto al problema de clasificación. El uso de este tipo de modelo viene apoyado en los resultados obtenidos por Schaerf et al. (2023) y trabajos previos aplicados al arte (Gatys et al. (2015)).

Con este propósito, se usan redes convolucionales preentrenadas, concretamente **ConvNeXtTiny**, un modelo reciente inspirado en la arquitectura de **Vision Transformers (ViT)** pero optimizado para mantener las ventajas de las **redes convolucionales jerárquicas**. ConvNeXt destaca por:

- Su eficiencia computacional: es más ligero que modelos más grandes (p. ej. ConvNeXt Base o Large), lo cual lo hace adecuado para conjuntos de datos limitados y hardware no tan potente.
- Su capacidad de extraer **representaciones ricas y abstractas** desde imágenes de tamaño medio (224 x 224 en este caso).
- Su robustez en tareas de clasificación transferida gracias a su entrenamiento previo en **ImageNet**.

Entrenamiento en dos fases. El proceso de entrenamiento se dividió en dos etapas, lo que permitió equilibrar la **estabilidad del aprendizaje** con la **capacidad de adaptación al dominio específico (arte pictórico español de los siglos XVII y XVIII)**:

- **Fase 1 Transfer Learning:**

Se congelaron todos los pesos del backbone ConvNeXtTiny y únicamente se entrenaron las capas superiores densas añadidas. Esto permitió que el modelo aprendiera una representación inicial de las pinturas sin sobreajustar rápidamente debido al bajo volumen de datos. Con este mismo propósito, se hizo uso de las técnicas de regularización L2 en la capa densa y de dropout después de esta capa.

Adicionalmente, se hizo uso de los *callbacks* de parada temprana con restauración de los mejores pesos y guardado de modelo para hacer un uso más eficiente de los recursos en el entrenamiento.

- **Fase 2 Fine Tuning:**

Se descongelaron únicamente las últimas cinco capas convolucionales del backbone. Esto permitió un ajuste fino con un menor learning rate sobre patrones más específicos del dominio artístico (textura del lienzo, paleta de colores, estilo pictórico), aprovechando la generalización aprendida previamente. Además, se usaron los mismos *callbacks* que en la primera fase.

- **Predicción final:** 1 para Goya, 0 para Velázquez
- **Probabilidad estimada** de que el cuadro pertenezca a Goya

4.2.3. Modelo Swin-Tiny

Desde la perspectiva de los Vision Transformers, se empleó Swin Transformer Tiny (Swin-Tiny), un modelo preentrenado en ImageNet 1k. Es una arquitectura jerárquica que organiza la autoatención en ventanas locales de 7×7 celdas (tokens). En cada bloque, la atención se calcula únicamente dentro de cada ventana, lo que reduce de forma significativa el coste computacional respecto a la atención global y, al mismo tiempo, mantiene la capacidad de capturar dependencias locales.

Para evitar que la información quede restringida a compartimentos fijos, los bloques alternan entre ventanas alineadas y ventanas desplazadas. En este último caso, cada ventana de 7×7 celdas se desplaza 3 celdas en horizontal y vertical, lo que garantiza que las celdas pasen a formar parte de ventanas distintas en bloques sucesivos y la atención pueda propagarse a regiones adyacentes.

Adicionalmente, el modelo aplica una fusión jerárquica de parches, que reduce gradualmente la resolución espacial mientras incrementa la dimensionalidad de las celdas, conformando así una pirámide de representaciones. En concreto, la imagen de entrada (224×224 px) se divide en celdas de 4×4 px, generando una cuadrícula de $56 \times 56 = 3136$ celdas; cada celda se proyecta a un vector de 96 dimensiones (patch embedding). Posteriormente, tres etapas de patch merging agrupan 2×2 celdas, reduciendo la resolución de $56 \rightarrow 28 \rightarrow 14 \rightarrow 7$ y aumentando los canales de $96 \rightarrow 192 \rightarrow 384 \rightarrow 768$.

De esta manera, cada celda representa áreas cada vez mayores de la imagen (4×4 , 8×8 , 16×16 y 32×32 px), mientras la capacidad descriptiva aumenta en profundidad. Es importante señalar que, tras el último patch merging, la rejilla resultante es de 7×7 celdas, exactamente el mismo tamaño que la ventana de autoatención. Por tanto, en este nivel la atención se convierte en global (una sola ventana cubre toda la imagen), y el desplazamiento de ventanas deja de aportar información adicional, aunque se mantiene en la arquitectura por coherencia estructural.

Gracias a esta estructura, Swin-Tiny integra tanto información local (detalles como pinceladas o texturas) como global (composición y estructura general de la obra), lo que lo convierte en un modelo especialmente adecuado para la atribución artística. La elección metodológica se fundamenta en trabajos como Schaerf et al. (2023), quienes demostraron que los Vision Transformers basados en ventanas jerárquicas superan a arquitecturas convencionales en tareas de autenticación de obras de arte.

Resultados




Figura 9: Matriz de confusión en el conjunto de prueba para CNN.

- **Accuracy:** 0,8529
- **Recall:** 0,8434
- **F1-score:** 0,8478

El modelo final genera como salida un JSON con la siguiente información:




Figura 10: Esquema ilustrativo del patch embedding y la pirámide jerárquica en Swin-Tiny. *Nota:* proporciones y cuadrículas no están a escala; se muestran con fines explicativos.

1. Estrategia de generación de parches

Antes de ingresar al modelo, cada obra se dividió en parches según su resolución:

- **Obras grandes** ($\min(W, H) > 1024$ px): división en 16 parches (4×4), cada uno de tamaño $\approx \frac{W}{4} \times \frac{H}{4}$.
- **Obras medianas** ($512 < \min(W, H) \leq 1024$ px): división en 4 parches (2×2), cada uno $\approx \frac{W}{2} \times \frac{H}{2}$.
- **Obras pequeñas:** la imagen se mantiene completa.

En todos los casos se añadió un recorte cuadrado central, de tamaño igual al lado menor de la obra. De esta forma, cada obra generó entre 2 y 17 parches, todos redimensionados a 224×224 píxeles en formato RGB para garantizar homogeneidad en la entrada del modelo. Los píxeles sobrantes en divisiones no exactas fueron descartados para mantener la regularidad de los parches. Esto se observa en la Figura 12.

2. Técnicas de balanceo de clases

El conjunto de entrenamiento presentaba desbalanceo (117 obras de Goya frente a 64 de Velázquez). Para evitar sesgo hacia la clase mayoritaria se empleó un *WeightedRandomSampler*, que asignó a cada obra un peso inversamente proporcional a la frecuencia de su clase.

Una vez aplicado el *WeightedRandomSampler*, en la práctica, en una época de muestreo se obtuvieron 100 muestras de Goya y 81 de Velázquez. Aunque no es un reparto perfectamente 50/50, sí resulta equilibrado. Es importante aclarar que

estas cifras corresponden a muestras en esa época (con posibles repeticiones) y no al número real de obras únicas en el dataset.

3. Configuración del entrenamiento y función de decisión

El modelo se configuró con una capa lineal final que produce un único logit por parche, usado para clasificación binaria (Velázquez=0, Goya=1).

- **Entrenamiento.** La pérdida se calcula a nivel de parche, replicando la etiqueta de la imagen (0 en caso de Velázquez y 1 en el caso de Goya).
- **Validación y test.** Los logits de los parches y del recorte central se agregan mediante la media para obtener un único logit por obra se agregan por media para obtener un único logit por obra z_{obra} . A este valor se aplica la función sigmoide para obtener la probabilidad de pertenencia a la clase Goya p_{obra} .

$$p_{obra} = \sigma(z_{obra}) = \frac{1}{1 + e^{-z_{obra}}}.$$

■ Decisión final.

$$\hat{y} = \begin{cases} 1, & \text{si } p_{obra} \geq 0,5 \text{ (Goya)}, \\ 0, & \text{en caso contrario (Velázquez)}. \end{cases}$$

Resumen. Se entrena a nivel de parches (un logit por parche y pérdida por parche) y se evalúa a nivel de obra (media de logits de parches + recorte central).

La optimización se realizó con Adam $lr = 1 \times 10^{-4}$ y data augmentation (recortes aleatorios, volteo horizontales, variaciones de color). Se implementó early stopping con paciencia de 10 épocas, guardando el modelo con menor pérdida en validación.

4. Resultados

En el conjunto de prueba se obtuvieron resultados sólidos y equilibrados:

- **Accuracy:** 0,9412
- **Precisión:** 0,9688
- **Recall:** 0,9394
- **F1-score:** 0,9538




Figura 11: Matriz de confusión en el conjunto de prueba para Swin-Tiny.

Estos resultados confirman que el modelo logra diferenciar adecuadamente entre los estilos pictóricos de ambos autores, capturando tanto características locales como patrones globales, en línea con lo descrito por Schaerf et al. (2023).

5. Salida del modelo

El resultado del modelo se estructura en un JSON, que almacena la siguiente información:

- **Predicción final:** valor binario $\hat{y} \in \{0, 1\}$ (1 = Goya, 0 = Velázquez).
- **Probabilidad asociada:** valor continuo $p_{obra} \in [0, 1]$ que indica la estimación de que la obra pertenezca a Goya.

Este formato de salida permite tanto la interpretación directa de la decisión del modelo como el análisis probabilístico de su confianza, facilitando su integración en aplicaciones posteriores de autenticación o atribución artística.




Figura 12: Ejemplo de generación de parches (4x4) y recorte central aplicado a la obra *Cristo en casa de Marta y María* (Velázquez, 1618).

Modelos de extracción de caras

Para detectar las caras de los cuadros se ha usado la librería **MediaPipe** desarrollada por Google, que ofrece una función específica de `face_detection` accesible a través de su API. La documentación oficial se encuentra disponible en el repositorio de GitHub de Google AI Edge¹. Esta función utiliza un modelo llamado *BlazeFace* Bazarevsky et al. (2019) para la detección de caras. La arquitectura de *BlazeFace* se fundamenta en un extractor de características inspirado en MobileNetV2. Aunque está pensado para maximizar la eficiencia en GPUs móviles, funciona perfectamente con el caso que nos ocupa. El modelo adopta un enfoque de detección de una sola etapa (single-shot), similar a SSD, pero con un esquema de anclas optimizado que reduce la complejidad durante la inferencia. Además, incorpora un mecanismo alternativo a la supresión de no-máximos (NMS), denominado *tie resolution*, que resuelve solapamientos de manera más eficiente en GPU.

En el desarrollo de este trabajo, se ha optado por el uso del parámetro `model_selection=1`, correspondiente al modelo de rango completo, cuya capacidad de detección se extiende hasta aproximadamente cinco metros para fotografías. Esta configuración resulta más adecuada en el caso de obras pictóricas, en las que los rostros pueden parecer de menor tamaño en relación con la superficie total del lienzo. Se opta por reducir el umbral de confianza mínimo a `min_detection_confidence=0.25`, con el objetivo de capturar rostros que, debido al estilo pictórico, la iluminación o la degradación de la obra, puedan presentar menos rasgos distintivos que un rostro humano en condiciones naturales. Con ello se prioriza la exhaustividad en la detección frente a la precisión. Sin embargo, antes de introducir las caras al *dataset* se han eliminado los falsos positivos, que no eran demasiados.

La implementación también incluye un filtrado basado en un tamaño mínimo de píxeles, fijado en un cuadrado de 128 píxeles. Esto asegura que los fragmentos faciales recortados tengan la resolución adecuada para su posterior procesamiento a través de los modelos de clasificación de autorías empleadas. Cada detección válida se extrae y se guarda en un subdirectorio separado, lo que facilita el seguimiento de cada rostro en relación con la obra original de la que proviene. Esta estrategia de organización ayuda a estructurar de manera sistemática el conjunto de datos, asegurando la calidad de las muestras utilizadas para entrenar el clasificador que se encargará de diferenciar entre las distintas autorías.

El objetivo de la extracción de caras de los cuadros es el de entrenar con estos datos a dos modelos que permitan distinguir si pertenecen a un cuadro de Goya o uno de Velázquez.



Figura 13: Ejemplo de la extracción de caras de un cuadro de Velázquez.

4.2.4. Modelo ViT (caras)

Para clasificar las caras, procedí como en el artículo de Lyu, S. et al. (2004), donde se extraen *features* de caras de cuadros basándose utilizando *wavelets*, una suerte de redes convolucionales. En lugar de extraer las *features* manualmente, en este apartado se emplea el modelo CLIP (Contrastive Language Image Pretraining) de OpenAI, que cuenta con el *visual encoder* ViT-B/16². CLIP es un modelo bimodal implementado en PyTorch, que ha sido entrenado por OpenAI con pares de imagen y texto, codificando ambos en un mismo espacio embebido. Aunque no se hace uso de la parte de codificación de textos, las *features* que se obtienen con ViT-B/16 serán más que suficientes para poder distinguir los cuadros de ambos autores. Este *encoder* es un *Vision Transformer*, es decir, cada imagen se subdivide en regiones de 16×16 píxeles, que se linealizan y proyectan a un espacio de embeddings utilizando bloques de *transformers* y *self-attention*. Al haber sido entrenado con un gran volumen de datos, las *features* en el espacio de *embeddings* proporcionan representaciones visuales robustas y transferibles, que está alineado con lo buscado para la clasificación binaria.

Para entrenar el modelo con los datos disponibles, se añade una capa con dos *logits* (dos neuronas sin activación, es decir, un cálculo lineal), uno por clase. Se utiliza **CrossEntropyLoss** como función de pérdida. Una vez entrenado el modelo, estos valores se convierten en probabilidad mediante una **softmax**. Se usan las etiquetas 0 para Velázquez y 1 para Goya.

La estrategia empleada es la de *fine-tuning*, aunque de manera controlada. Es decir, al principio se usa solo *transfer learning*, congelándose todas las capas del modelo (*backbone*) salvo la última (*head*). Cuando ha transcurrido un tiempo de entrenamiento, se descongela el (*backbone*), pero utilizando el *optimizer* AdamW, que usa *learning rates* distintos para *head* (mayor) y *backbone* (menor). Además, se usa un *scheduler*, que

¹https://github.com/google-ai-edge/mediapipe/blob/master/docs/solutions/face_detection.md

²<https://github.com/openai/CLIP>

modifica los *learning rates* según lo requiera el entrenamiento. En adición, se aplican tres medidas de regularización para evitar el *overfitting* con los datos de entrenamiento: *label smoothing* (las etiquetas valen 0.95 y 0.05 en lugar de 1 y 0), selección del mejor modelo contrastando el conjunto de validación usando **macro-F1** y limitación del tiempo de entrenamiento.

En la preparación de los datos se replica la canalización de preprocesado de CLIP (redimensionando las imágenes de las caras a 224×224 y normalización). Además, como el conjunto de entrenamiento no cuenta con demasiadas imágenes de caras, se aplican técnicas de *data augmentation* suaves. Se emplea *RandomResizedCrop*, *Horizontal-Flip*, *ColorJitter* leve, *RandomGrayscale* y *Gaussian-Blur*, con el objetivo de mejorar la generalización.

En cuanto a los resultados, utilizando 0.5 como punto de corte, el modelo consigue:

- **Accuracy en train:** 0.9355
- **Accuracy en test:** 0.9737

Lo cual es un resultado bastante satisfactorio. Además las matrices de confusión no indican que se produzca un desbalance muy grande con alguna de las dos clases:




Figura 14: ViT train.



Figura 15: ViT test.

4.2.5. Modelo de Embeddings (caras)

La idea principal de este modelo es aprovechar el poder de representación de modelos de embeddings preentrenados para caracterizar las caras presentes en los cuadros de Goya y Velázquez, extraídas previamente, y posteriormente entrenar un clasificador ligero que distinga entre ambos artistas.

El enfoque busca ser complementario a otros modelos que analizan los cuadros completos (CNNs, Swin Transformers, etc.), centrándose únicamente en las caras, ya que se considera que los retratos faciales contienen gran parte de la información estilística del autor.

Cada imagen de cara se procesa con el modelo *laion/CLIP-ViT-g-14-laion2B-s12B-b42K* (publicado por LAION en Hugging Face), basado en una arquitectura ViT-g/14 entrenada sobre 2 mil millones de pares imagen-texto. Se evaluaron varias capas internas del modelo con el objetivo de identificar aquella que ofreciera mayor *accuracy* en el conjunto de validación. Para ello se emplearon dos métricas de similitud, la distancia euclídea y la distancia coseno, aplicadas sobre los embeddings obtenidos. Como resultado de esta evaluación, se seleccionó la capa 34.

Los embeddings resultantes, vectores de dimensión 1024, se emplean como entrada de un clasificador de regresión logística. La salida del clasificador es la probabilidad de que la cara corresponda a Goya; aplicando un umbral de 0.5 se decide la clase predicha (Goya=1, Velázquez=0). Para cuadros con múltiples caras se calculó la media de probabilidades de todas las caras detectadas, obteniendo una única predicción por cuadro.

En términos de resultados, el modelo alcanzó una precisión de **0.9211** el conjunto de test, y la matriz de confusión mostró un buen equilibrio entre sensibilidad y especificidad, con ligeras confusiones en cuadros con pocas detecciones faciales o falta de calidad en estas. Como se puede observar en la siguiente matriz de confusión para el conjunto test (Figura 16).




Figura 16: Matriz de confusión en el conjunto de test para embeddings.

4.3. Modelos descartados

4.3.1. Modelo de extracción de trazos pictóricos

Durante el desarrollo de este trabajo se exploró una línea experimental inspirada en Prudviraj and Jamwal (2025), cuyo objetivo era la representación vectorial de regiones de una pintura a partir de sus trazos de pincel. La motivación de esta aproximación fue incorporar, como variable adicional en el modelo de regresión logística final, una caracterización explícita de la gestualidad pictórica.

Este planteamiento se enmarca en una línea de investigación más amplia sobre el análisis de trazos como huella estilística del artista. En este sentido, Elgammal et al. (2017) mostraron cómo la caracterización a nivel de trazo podía emplearse con éxito en la atribución y autenticación de dibujos de Picasso y Matisse, donde cada línea de lápiz o tinta constituye una unidad visual fácilmente separable. Inspirados por este enfoque, en este caso se buscó trasladar el principio al dominio de la pintura al óleo. No obstante, a diferencia de los dibujos lineales, en Goya y Velázquez la gestualidad pictórica es más heterogénea y menos explícita, lo que dificultó obtener representaciones discriminativas útiles para la tarea de autenticación.

Segmentación con SAM-Huge y partición disjunta. Sea $\Omega \subset \mathbb{Z}^2$ el dominio de la imagen con dimensiones $H \times W$. Se utilizó **Segment Anything Model (ViT-H SAM)** a través del *Automatic Mask Generator (AMG)* de la librería oficial de Meta AI³ para producir máscaras binarias potencialmente solapadas:

$$\mathcal{M} = \{M_k \subset \Omega \mid k = 1, \dots, K\}, \quad \chi_{M_k}(p) \in \{0, 1\}.$$

A partir de dichas máscaras se construyó una partición disjunta y completa en regiones R_i , que a efectos prácticos se identifican con los segmentos Seg_n de la imagen:

$$\bigcup_{i=1}^C R_i \sqcup R_{bg} = \Omega, \quad R_i \equiv Seg_n.$$

El proceso fue el siguiente: (i) se ordenaron las máscaras por área descendente y, para cada una de ellas, se tomó únicamente su contribución *no solapada* respecto a las ya aceptadas; si dicha contribución era inferior al 2% de $H \times W$, se marcó como región *pequeña*; (ii) las contribuciones no solapadas que superaban el umbral se etiquetaron secuencialmente como regiones *grandes*; (iii) cada región pequeña se fusionó con la región grande más cercana en términos de distancia euclídea, empleando transformadas de distancia precomputadas; y (iv) los píxeles restantes sin etiqueta se asignaron al fondo R_{bg} .

³<https://github.com/facebookresearch/segment-anything>

⁴<https://github.com/shapely/shapely>



Figura 17: *El Aquelarre*. Figura 18: Regiones disjuntas tras (i)–(iv).

Vectorización con vtracer y construcción de trazos. Cada segmento Seg_n se procesó mediante **vtracer**, obteniendo un conjunto de regiones vectorizadas en formato SVG:

$$V_R_m = Vect(Seg_n), \quad m = 1, \dots, M, \quad n = 1, \dots, N.$$

Estas regiones vectorizadas describen la imagen en términos de polígonos coloreados. Sobre cada polígono P se aplicó la librería **Shapely**⁴, en particular la función `minimum_rotated_rectangle`, que calcula la caja mínima rotada que contiene a P . A partir de esta aproximación se derivaron atributos geométricos que definen el trazo estilizado: orientación, ancho, alto, centroide y color. Formalmente, se construyó un descriptor:

$$\phi(P) = (\theta, \text{width}, \text{height}, \text{center}_x, \text{center}_y, \text{color}_{\text{RGB}}),$$

donde la orientación $\theta(P)$ se definió a partir del vector director de la caja mínima rotada. El conjunto de descriptores $\Phi = \{\phi(P_j)\}_j$ asociado a cada segmento constituyó la representación de los trazos pictóricos. Mientras que en Prudviraj and Jamwal (2025) la vectorización se aplicaba con éxito a la obra de Van Gogh, donde la pincelada es muy marcada y repetitiva, aquí se replicó ese principio sin resultados satisfactorios. La idea fue representar cada región no como un parche irregular, sino como un trazo estilizado con atributos geométricos claramente definidos.

Limitaciones encontradas.

- **Coste computacional:** la combinación de SAM-Huge, la fusión por distancia y la vectorización con **vtracer** resultó muy costosa.
- **Calidad de la abstracción:** los trazos generados no reflejaban fielmente la pincelada en autores con gestualidad más sutil (Goya, Velázquez).
- **Dependencia estilística:** el método mostró mayor potencial en artistas de pincelada evidente (e.g. Van Gogh) que en la casuística estudiada.

- **Sensibilidad a hiperparámetros:** variaciones en los parámetros del AMG o en la resolución de entrada producían segmentaciones y trazos inestables.

Conclusión y aplicabilidad. El procedimiento garantiza una partición disjunta formalmente correcta y define descriptores geométricos de trazos $\phi(P)$. Sin embargo, en el caso concreto de Goya vs. Velázquez no aportó señal discriminante suficiente y supuso una carga computacional excesiva. Esta metodología podría resultar más prometedora en estilos pictóricos con gestualidad dominante (impresionismo, expresionismo) o en tareas de estilización digital más que de autenticación.

4.3.2. Modelo lumínico

Otro modelo que se intentó aplicar fue el expuesto en el paper de Bleier et al. (2011), en concreto, uno basado en la iluminación segmentando en superpíxeles, estimando un iluminante por región con varios algoritmos de color constancy y luego fusionando esas estimaciones.

No resultó viable ya que el objetivo es analizar o clasificar obras de arte digitalizadas. De entrada, la estimación del color de la luz a partir de una única imagen es un problema subdeterminado: cada píxel mezcla reflectancia (la paleta y los pigmentos, que son rasgos estilísticos) e iluminación. El propio trabajo admite esa indeterminación y propone suavizarla con segmentación y fusión, lo que introduce el riesgo de confundir variaciones de paleta del autor con cambios de luz estimados.

Además, el método descansa en supuestos de adquisición que rara vez se cumplen en repositorios de museos o catálogos: datos RAW lineales ($\gamma = 1.0$), sin balance de blancos ni procesado, y con cámara y óptica fijas; y escenas mayoritariamente lambertianas (difusas), evitando interreflexiones hasta el punto de pintar de gris las escenas para medir un ground truth local del iluminante. Esta disciplina de captura es precisamente lo que no existe cuando trabajamos con reproducciones ya procesadas (balanceadas, con curvas de tono, perfiles ICC, compresiones distintas) y con superficies pictóricas barnizadas o craqueladas. En esas condiciones, las estimaciones de iluminante dejan de ser estables o comparables entre obras y colecciones.

Técnicamente, llevar los estimadores a escala local agrava otra limitación clave: al reducir cada región a un superpíxel casi monocromo, los métodos estadísticos pierden la diversidad cromática sobre la que se apoyan (Gray World, Gamut, Bayesian), y su error crece. Esto también se contempla en el paper.

Finalmente, la generalización entre dominios es frágil. En sus propios experimentos, entrenar en una base y evaluar en otra ya degrada el rendimiento; si

se pasa a imágenes heterogéneas de distintas instituciones cámaras, escáneres y flujos de posprocesado dispares la deriva de dominio empeora, y el modelo termina capturando peculiaridades del proceso de digitalización antes que propiedades de la obra.

4.4. Agregación y combinación

Una vez desarrollados cada uno de los modelos individuales, cada uno con sus explicabilidades y sus probabilidades obtenidas de pertenecer a uno u otro artista, se precisa una manera de obtener una predicción final.

Para obtener la predicción final, se podría simplemente hacer un voto mayoritario para el valor, o una media simple de las probabilidades de cada modelo. Sin embargo, esta opción se descartó, ya que, pese al valor explicativo de todos los modelos elegidos, hay claramente modelos que funcionan mucho mejor que otros, y a los que se desea dar más peso en el valor final. Por ello, se decidió entrenar un metamodelo que combinase todos.

Sin embargo, este metamodelo también debía seguir la filosofía del resto del trabajo, y ser lo más explicable posible. Además, una vez ya obtenidas las probabilidades de cada modelo, se tienen muy pocas variables, y una muestra de menos de 200 imágenes para entrenar. Por estos motivos, se optó por combinar todas las probabilidades en una logística.

Para ello, se siguen los siguientes pasos:

1. Probabilidades individuales

Se obtiene, para cada modelo, las probabilidades que estos asignan tanto al conjunto de entrenamiento, como al de validación y testeo. Estas probabilidades se guardan en un dataframe, con el nombre de cada modelo como columna.

2. Logodds

Dadas estas probabilidades, se obtienen los logodds asociados a las probabilidades (con límites superiores e inferiores para evitar problemas con la función logaritmo derivados de las probabilidades 0 o 1)

3. Entrenamiento logística

Con estos logodds, se entrena una regresión logística. Para ello, se usa un factor de regularización $C = 0,75$. Esta regularización es clave para evitar el sobreajuste meta-modélico, ya que al utilizar la misma muestra de train para el ensamblado de modelos que para cada uno de ellos, se puede caer en este sobreajuste.

Sobre el modelo de caras, se evaluó la posibilidad de entrenar dos logísticas distintas: una con los cuadros que tienen caras, y otra con los que no. Sin embargo, esto se descartó debido al bajo número de observaciones con las que ya se cuenta, que quedaría aún más mermado separando en dos. En su lugar, se optó por usar los cuadros en los que no se detecta cara como probabilidad 0,5, y se crea una variable auxiliar de si el cuadro tiene caras o no, que se usa para entrenar la logística.

El modelo da los siguientes resultados:




Figura 21: Matriz de confusión del ensamblado en test.

- **Accuracy:** 0,98
- **Recall:** 1,00
- **F1-score:** 0,99

4. **Aplicación a imágenes** Para aplicar el modelo a una imagen, se aplica un pipeline que para cada una obtenga el resultado de los modelos individuales, obtenga los logodds y obtenga el valor final de la logística.

4.5. Interfaz con LLMs

El uso de los LLM para aportar explicabilidad fue la idea desde un principio, sobre para interpretar los parámetros numéricos como frases en lenguaje natural, de manera que el resultado de los modelos pudiera ser interpretado no solo por gente de entorno computacional-matemático, sino también por gente de entorno artístico, que son el público objetivo.

Sin embargo, las técnicas de explicabilidad utilizadas en los modelos basados en redes neuronales aplicadas en este trabajo son visuales, por lo que no necesitan de la explicación de un modelo de lenguaje natural.

Sin embargo, sí que se ha considerado que en el modelo cromático y en la regresión logística final, añadir una capa de explicación del LLM daba un valor añadido.

Respecto a la regresión logística, la misión del modelo es sencilla: explicar en palabras qué modelos

son más y menos importantes, y resaltar si, dado un cuadro, la importancia que tienen las caras o el color es superior o inferior a la media.

Respecto al modelo cromático, aquí la interpretación de un LLM de los parámetros del modelo sí que es muy relevante, ya que puede interpretar, de los centroides, desviaciones de los canales de colores, y otras estadísticas de estos, conclusiones pictóricas reales. Por ejemplo, de saber que el centroide mayoritario tiene coordenadas (127,74,74), un LLM puede interpretar que se trata de un marrón oscuro muy típico entre las obras de un cierto autor, lo que puede explicar el elevado peso de este en la decisión del modelo de Random Forest.

5. Conclusiones

5.1. Valor de combinar XAI + LLM

En este trabajo ha quedado claro que los modelos de clasificación de imágenes basados en redes convolucionales y *vision transformers* son más que suficiente para hacer una predicción de autoría. Sin embargo, también se ha visto cómo la combinación de modelos de técnicas de Inteligencia Artificial Explicable (XAI) y modelos de lenguaje (LLMs) constituyen una herramienta conveniente a la hora de interpretar el resultado de los modelos. La integración de Grad-CAM, Integrated Gradients, SHAP, SmoothGrad, Attention Rollout y LIME ha permitido no solo obtener predicciones con altos niveles de precisión, sino también dotar a dichas predicciones de un contexto explicativo basado en las técnicas tradicionales de autenticación usadas por expertos en arte.

Este nuevo enfoque actúa como un acercamiento entre las técnicas clásicas de autenticación y los métodos basados en inteligencia artificial, permitiendo trasladar la rigurosidad y trazabilidad propias del análisis tradicional al ámbito computacional. Al integrar explicaciones visuales y textuales junto a las predicciones probabilísticas, se favorece la interpretabilidad de los resultados, dejando de ser estos meros outputs que han de ser o no creídos. Además, se ha intentado que los modelos usados, tanto como para clasificar como para entrenar, sigan criterios similares a los utilizados en estudios tradicionales. De este modo, se generan modelos de autenticación más robustos, transparentes y alineados con las prácticas académica.

Uno de los objetivos de este proyecto es demostrar que trabajos similares pueden ser la base para un marco metodológico híbrido en el que la IA complementa, en lugar de sustituir, el juicio experto.

5.2. Resultados

Las métricas de los modelos individuales se encuentran en el Cuadro 4. Los resultados muestran una evolución clara en el rendimiento a medida que se incrementa la complejidad y la especialización de los modelos. El metamodelo, la regresión logística, consigue mejores métricas que cualquiera de los modelos individuales. Por lo que los modelos, que toman como referencia distintas características de los cuadros, como el color, el cuadro completo, parches, o las caras de este, y están basados en distintas arquitecturas, han demostrado que son complementarios, y que cada enfoque capta rasgos estilísticos distintos.

	Accuracy	F1-score
Modelo Cromático	0,7098	0,7476
Modelo CNN	0.8529	0.8478
Modelo Swin-Tiny	0.9412	0.9538
Modelo ViT (caras)	0.9737	0.9804
Embeddings (caras)	0.9211	0.9362
Regresión logística final	0,9800	0,9897

Cuadro 4: Tabla de resultados.

5.3. Limitaciones

Entre las limitaciones principales destacan el tamaño reducido y el desbalance del dataset, la heterogeneidad en la calidad de las imágenes y la dificultad para capturar características estilísticas en modelos complejos como los de trazos pictóricos.

Este es un problema transversal a los trabajos con obras artísticas, ya que hasta los catálogos de los autores más prolíficos, raramente superan las 500 obras. En el caso de Valázquez, hay muchas autorías discutidas y no nos ha llegado toda su obra, por lo que su catálogo disponible es menor que el de Goya, que fue un autor más prolífico y más cercano a nuestro tiempo. Asimismo, la ejecución de modelos avanzados (p.ej. Segment Anything o embeddings de gran tamaño) ha implicado costes computacionales elevados, teniendo que utilizar CPUs de *Google Collaboratory Pro*.

Por último, las explicaciones generadas por los LLM, aunque útiles, pueden introducir sesgos o interpretaciones no deseadas si no se validan adecuadamente; o por otro lado tomar como propias de un artista cualidades que son comunes a ambos.

5.4. Posibles extensiones

Es en este apartado donde este trabajo puede tomar valor. Este, aunque cumple una tarea sencilla como la de distinguir entre dos autores, puede servir como base para dos tareas fundamentales en el mundo del arte y en la que muchos expertos han fallado. Estos problemas son:

- La atribución histórica de autorías
- La detección de falsificaciones de obras de arte

Todavía no se sabe a ciencia cierta si el Coloso es un cuadro de Goya o si la Gioconda que se recuperó después de su robo en 1911 es la auténtica. El mercado del arte movió el año pasado más de 57.500 millones de dólares Marcos, Ana (2025), y el trabajo de los falseadores de obras de arte es muy cotizado. Una herramienta fiable y rápida que fuera capaz de establecer una primera opinión sobre la autenticidad de una obra tendría un papel fundamental en el mercado.

Aunque el modelo ensamblado no es capaz de llegar a estos niveles de precisión, con los suficientes recursos, se podría construir una herramienta funcional. Para ello se necesitaría:

- Incorporar nuevas fuentes de datos y aumentar la diversidad de autores para mejorar la generalización.
- Explorar modelos multimodales que integren descripciones textuales históricas junto a la imagen.
- Profundizar en la segmentación y análisis de otros elementos (manos, fondos, gestualidad pictórica) para capturar señales adicionales.
- Afinar y entrenar específicamente LLMs en dominios artísticos para obtener explicaciones más precisas y contextualizadas.

En conjunto, este TFM pone de manifiesto el potencial de las técnicas de IA explicable y los modelos de lenguaje como herramientas de apoyo a la investigación en historia del arte, ofreciendo un marco metodológico replicable y ampliable a otros contextos de autenticación y análisis estilístico.

Más allá de la clasificación entre dos autores concretos, el enfoque desarrollado puede sentar las bases para abordar problemas de enorme relevancia como la atribución histórica de autorías o la detección temprana de falsificaciones, ámbitos donde incluso expertos consagrados han encontrado dificultades y que mueven cifras multimillonarias en el mercado del arte. Si se contara con recursos suficientes más datos, diversidad de autores, integración de información multimodal (imagen y textos históricos) y un análisis más profundo de elementos pictóricos como manos, fondos o gestualidad sería posible evolucionar hacia una herramienta funcional que, sin sustituir al juicio experto, proporcionara una primera valoración informada, rápida y trazable de la autenticidad de una obra.

En este sentido, el presente TFM no solo demuestra la viabilidad técnica del enfoque, sino que también abre un camino para futuras investigaciones y desarrollos tecnológicos que podrían transformar la práctica museística, la conservación del patrimonio y el mercado del arte.


A. Aplicación desarrollada: arquitectura e interfaz

Como parte de este Trabajo de Fin de Máster se ha implementado una aplicación interactiva en **Streamlit**. La herramienta permite cargar una imagen de una pintura de Goya o de Velázquez, aplicar los distintos modelos entrenados, visualizar las explicaciones generadas por cada uno de ellos y, finalmente, combinar sus resultados mediante un meta-modelo de regresión logística que ofrece la decisión global. De manera complementaria, se han integrado modelos de lenguaje (LLM) en los módulos de color y logística, aportando explicaciones textuales enriquecidas que vinculan la interpretación técnica con el contexto histórico-artístico.

A.1. Estructura del proyecto

La aplicación sigue una arquitectura modular. En la raíz se encuentran los archivos **app.py** (página principal con el resumen de métricas y visualizaciones) y **main.py** (punto de entrada y barra de navegación). La carpeta **core/** contiene la configuración, carga de modelos, gestión del estado de sesión y utilidades de visualización. Los modelos entrenados se almacenan en **modelos/**, mientras que las diferentes pestañas de la interfaz se definen en **pages/** (**01_Color.py**, **02_CNN.py**, **03_Swin.py**, **04_Caras.py**, **05_Log.py**). Además, se incluyen directorios auxiliares con las funciones específicas de explicabilidad utilizadas. Se adjunta el repositorio con los códigos y rutas utilizadas en el enlace. ^a

^a<https://github.com/FineArtAuthentication/TFM>




A.2. Descripción de las pestañas

- **La página principal** (**app.py**) ofrece una visión global de la predicción: muestra el autor estimado con su nivel de confianza, las probabilidades individuales de cada modelo en forma de tarjetas y, adicionalmente, una visualización de tipo cascada (*waterfall*) que descompone la contribución de cada modelo en la decisión logística. También se incluye un gráfico comparativo de aportes y una métrica de consenso entre los modelos, que permiten valorar la coherencia de sus predicciones.



- **Modelo de Color (Random Forest).** Se basa en un Random Forest entrenado sobre descriptores cromáticos de las obras. La interfaz muestra la paleta dominante de la pintura junto con la importancia relativa de cada variable mediante *SHAP TreeExplainer*. Como complemento, un **LLM** interpreta los resultados en clave artística, explicando cómo el uso del color en la obra analizada se relaciona con las técnicas y estilos habituales de los autores estudiados.



El modelo arroja un resultado de "0", es decir, atribuye la autoría a Velázquez, con una probabilidad de Goya del 49,3% (por ende Velázquez en torno al 50,7%). Se trata de un caso muy frontal, casi cívado, pero algunos rasgos inclinan la balanza hacia el pintor sevillano más que al aragonés.

En primer lugar, la pintura exhibe un porcentaje de tonos oscuros altísimo (84,7%) y apenas un 0,018% de tonos claros. Ese dominio de la penumbra y la casi ausencia de zonas luminosas recuerdan al clasicismo tardo y naturalista de Velázquez, que evita subrayados demasiado dramáticos o focos de luz intensos, a diferencia de Goya, que a menudo recurre a contrastes más rotundos.

El rango dinámico de valor es muy amplio (0,34) pero, paradójicamente, la entropía de color es también alta (11,83 bits), lo que señala una riqueza de matices dentro de una paleta contenida. Los medios de tono y saturación en espacios HSV ($\bar{v}=0,208$, $s=0,480$) se mantienen en niveles moderados, sin los picos de saturación que Goya suele introducir para resaltar detalles emocionales o dramáticos más vivos.


Entre los colores principales, el más relevante (canal 1), casi negro con valores RGB 0,059-0,050-0,034, ocupa casi la mitad del rango (46,3%). Ese marrón-oscuro-grisáceo refuerza la atmósfera introspectiva y soñolienta característica de Velázquez. El segundo color (RGB 0,144-0,026-0,062) aparece en torno al 10,7% de la superficie y, aunque su propio impacto empuja ligeramente hacia Goya, su notable proporción frente a los demás añade más peso a la lectura tenebrosa velazqueña.

La curiosa de la saturación en HSV resulta especialmente significativa (valor 0,18, impacto positivo hacia Goya), porque revela que, pese al bajo nivel absoluto de saturación, ésta se concentra en unos intervalos muy precisos. Velázquez, fiel a una paleta uniforme y matizada, tiende a solapes de tonos muy próximos, mientras que Goya extiende con más libertad sus gamas. No obstante, en este caso la concentración en sí es tan atrevida que el modelo la interpreta en ambos sentidos, de ahí la cercanía de probabilidades.


Otro rasgo definitorio es la asimetría en el canal azul (diferencia, $rgb_b = -2,83$, con impacto negativo hacia Goya), que indica una rala muy alargada hacia valores bajos de azul. Esa preeminencia de azules profundos y grises azablanos, pocas veces vistos tan intensos en la obra de Goya, encaja mejor con la sutil presencia de azules apagados que acompañan a Velázquez en ciertos fondos o túnicas.

Resumiendo, la combinación de una paleta oscura y matizada, con alto rango dinámico de valores pero baja saturación media, junto al predominio de grises y azules muy oscuros y la marcada asimetría del canal azul, no sólo en el terreno de Velázquez. La probabilidad de Goya queda relegada a que algunos parámetros —como la concentración puntual de saturación— podrían corresponder también al vocabulario cromático del aragonés, pero en conjunto la lectura favorece la mano del sevillano.


- **CNN (ConvNeXt).** Red convolucional entrenada para discriminar entre Goya y Velázquez. Este módulo proporciona explicaciones visuales mediante *Grad-CAM*, que resalta las regiones más influyentes en la decisión, y *Integrated Gradients*, que distribuye la atribución sobre los píxeles de la imagen.



- **Swin-Tiny (Vision Transformer).** Modelo basado en *Transformers* que analiza la pintura a partir de parches. La explicación se centra en *Integrated Gradients* aplicados a los parches más relevantes, destacando tanto los que refuerzan como los que contradicen la predicción del modelo.



- **Caras (ViT + Embeddings).** Detecta y recorta los rostros presentes en la obra. Cada rostro se analiza mediante un ViT y un modelo de embeddings, obteniendo un score individual. Las explicaciones locales se generan mediante *SmoothGrad* y *Attention Rollout* (para el ViT) y *LIME* (para el modelo de embeddings).



...



- **Regresión Logística (Meta-modelo).** Consolida las salidas de todos los modelos anteriores en un clasificador logístico. Esta pestaña muestra la decisión final acompañada de la confianza asociada. Un **LLM** complementa la interpretación aportando un análisis textual que resume las predicciones individuales, evalúa la importancia relativa de cada modelo (a partir de las salidas previas mostradas en el Resumen) y justifica de forma narrativa la decisión final ofrecida por el sistema.



Referencias

- Abnar, S. and Zuidema, W. (2020). Quantifying attention flow in transformers.
- Adadi, A. and Berrada, M. (2018). Peeking inside the black-box: A survey on explainable artificial intelligence (xai). *IEEE Access*, 6:52138–52160.
- Arrieta, A. B., Díaz-Rodríguez, N., Ser, J. D., Bennetot, A., Tabik, S., Barbado, A., García, S., Gil-López, S., Molina, D., Benjamins, R., Chatila, R., and Herrera, F. (2019). Explainable artificial intelligence (xai): Concepts, taxonomies, opportunities and challenges toward responsible ai.
- Bazarevsky, V., Kartynnik, Y., Vakunov, A., Raveendran, K., and Grundmann, M. (2019). Blazeface: Sub-millisecond neural face detection on mobile gpus.
- Bleier, M., Riess, C., Beigpour, S., Eibenberger, E., Angelopoulou, E., Tröger, T., and Kaup, A. (2011). Color constancy and non-uniform illumination: Can existing algorithms work? In *2011 IEEE International Conference on Computer Vision Workshops (ICCV Workshops)*, pages 774–781.
- Brown, J. (1986). *Velázquez. Pintor y cortesano*. Alianza Editorial.
- Elgammal, A., Kang, Y., and Leeuw, M. D. (2017). Picasso, matisse, or a fake? automated analysis of drawings at the stroke level for attribution and authentication.
- Fundación Goya en Aragón (2025). Catálogo. <https://fundaciongoyaenaragon.es/catalogo>. Consultado el 22 de agosto de 2025.
- Gatys, L. A., Ecker, A. S., and Bethge, M. (2015). A neural algorithm of artistic style.
- Lyu, S., Rockmore, D., and Farid, H. (2004). A digital technique for art authentication. *Proceedings of the National Academy of Sciences*, 101(49):17006–17010.
- López-Rey, J. (1963). *Velázquez. A Catalogue Raisonné of his Oeuvre*. Faber and Faber.
- Marcos, Ana (2025). El mercado del arte huye del riesgo. <https://elpais.com/cultura/2025-04-12/el-mercado-del-arte-huye-del-riesgo-los-nuevos-compradores-que-gastan-menos-lo-mantienen-a-flote.html>. Consultado el 28 de agosto de 2025.
- Molnar, C. (2025). *Interpretable Machine Learning*. 3 edition.
- Panofsky, E. (1939). *Studies in Iconology: Humanistic Themes in the Art of the Renaissance*. Mary Flexner lectures on the humanities. Oxford University Press.
- Prudviraj, J. and Jamwal, V. (2025). Vectorized region based brush strokes for artistic rendering.
- Ribeiro, M. T., Singh, S., and Guestrin, C. (2016). "why should i trust you?": Explaining the predictions of any classifier.
- Sabatelli, M., Kestemont, M., Daelemans, W., and Geurts, P. (2019). Deep transfer learning for art classification problems. In Leal-Taixé, L. and Roth, S., editors, *Computer Vision – ECCV 2018 Workshops*, pages 631–646, Cham. Springer International Publishing.
- Sano, T. (2024). Explainable ai in art: visualizing artist’s characteristics in paintings for enhanced interpretation. *International Symposium on Affective Science and Engineering*, ISASE2024:1–3.
- Schaerf, L., Popovici, C., and Postma, E. (2023). Art authentication with vision transformers.
- Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., and Batra, D. (2019). Grad-cam: Visual explanations from deep networks via gradient-based localization. *International Journal of Computer Vision*, 128(2):336359.
- Smilkov, D., Thorat, N., Kim, B., Viégas, F., and Wattenberg, M. (2017). Smoothgrad: removing noise by adding noise.
- Sundararajan, M., Taly, A., and Yan, Q. (2017). Axiomatic attribution for deep networks.
- Wikipedia (2025a). Anexo: Cartones para tapices de goya. https://es.wikipedia.org/wiki/Anexo:Cartones_para_tapices_de_Goya. Consultado el 22 de agosto de 2025.
- Wikipedia (2025b). Anexo: Cuadros de goya. https://es.wikipedia.org/wiki/Anexo:Cuadros_de_Goya. Consultado el 22 de agosto de 2025.
- Wikipedia (2025c). Anexo: Cuadros de velázquez. https://es.wikipedia.org/wiki/Anexo:Cuadros_de_Vel%C3%A1zquez. Consultado el 22 de agosto de 2025.